

# Taller 4: Proyecto programación

16/05/2021

## Buen desempeño económico, la clave del éxito para un rendimiento sobresaliente en los juegos olímpicos.

El objetivo de este trabajo es determinar los efectos de las principales variables macroeconómicas en la cantidad de medallas olímpicas obtenidas en promedio.

### 1. Integrantes de grupo.

- *Joan Galeano R*
- *Nicolás González J*
- *Alejandro Guevara H*

### Paquetes

Para cumplir el objetivo del trabajo hacemos uso de RStudio como herramienta metodológica y de análisis. Se utilizan varios paquetes para el analisis, para el manejo de datos, graficos y modelos entre otros.

```
library(tidyverse)
library(rvest)
library(haven)
library(wbstats)
library(dplyr)
library(naniar)
library(knitr)
library(ggthemes)
library(readxl)
library(GGally)
library(Hmisc)
library(corrplot)
library(PerformanceAnalytics)
library(stargazer)
```

### Manejo de la base de datos

#### Variable explicada

Organizamos la base de datos, eliminamos datos faltantes y renombramos algunos países para evitar problemas (p.e: The Bahamas -> Bahamas, The) y de esta manera todas los nombres coinciden en las diferentes bases de datos sin afectar los datos de interés.

```

pagina <- "http://www.olympedia.org/statistics/medal/country"
pagina_desc <- read_html(pagina)

países <- pagina_desc %>% html_nodes("td:nth-child(1)") %>% html_text()

medallas <- pagina_desc %>% html_nodes("td:nth-child(6)") %>% html_text()
medallas <- as.integer(medallas)
medallas_por_pais <- tibble(países, medallas)

medallas_por_pais[4,1] <- "United Kingdom"
medallas_por_pais[7,1] <- "China"
medallas_por_pais[18,1] <- "Korea, Rep."
medallas_por_pais[43,1] <- "Iran, Islamic Rep."
medallas_por_pais[50,1] <- "Slovak Republic"
medallas_por_pais[59,1] <- "Egypt, Arab Rep."
medallas_por_pais[62,1] <- "Bahamas, The"
medallas_por_pais[83,1] <- "Venezuela, RB"
medallas_por_pais[84,1] <- "Serbia"
medallas_por_pais[97,1] <- "Cote d'Ivoire"
medallas_por_pais[98,1] <- "Hong Kong SAR, China"
medallas_por_pais[113,1] <- "Moldova"
medallas_por_pais[117,1] <- "Tanzania"
medallas_por_pais[121,1] <- "Kyrgyz Republic"
medallas_por_pais[122,1] <- "Saudi Arabia"

```

## Variables explicativas

En este caso, se presenta la Tasa de crecimiento del PIB como primera variable explicativa.

```

growth_gdp <- wb_data("NY.GDP.PCAP.KD.ZG", start_date = 1950, end_date = 2016)
growth_gdp <- tibble(growth_gdp$country, growth_gdp$date, growth_gdp$NY.GDP.PCAP.KD.ZG)
growth_gdp <- growth_gdp %>%
  rename(países = `growth_gdp$country`,
         fecha = `growth_gdp$date`,
         growth = `growth_gdp$NY.GDP.PCAP.KD.ZG`
  )
growth_gdp <- drop_na(growth_gdp)

growth_gdp_prom <- aggregate(growth_gdp$growth, list(growth_gdp$países), FUN=mean)
growth_gdp_prom <- growth_gdp_prom %>%
  rename(
    países = Group.1, GDP=x
  ) %>%
  mutate(GDP2=GDP^2)

```

A continuación, se usará la Tasa de crecimiento de la población.

```

growth_pob <- wb_data("SP.POP.GROW", start_date = 1950, end_date = 2016)
growth_pob <- tibble(growth_pob$country, growth_pob$date, growth_pob$SP.POP.GROW)
growth_pob <- growth_pob %>%
  rename(
    países = "growth_pob$country",

```

```

    fecha ="growth_pob$date",
    growth_p ="growth_pob$SP.POP.GROW"
  )
growth_pob <-drop_na(growth_pob)

growth_pob_prom <- aggregate(growth_pob$growth_p, list(growth_pob$países), FUN=mean)
growth_pob_prom <- growth_pob_prom %>%
  rename(
    países = Group.1, POB = x
  ) %>%
  mutate(POB2=POB^2)

```

También se decidió incluir la Tasa promedio de paro.

```

desempleo_total <- wb_data("SL.UEM.TOTL.ZS", start_date = 1950, end_date = 2016)
desempleo_total <- tibble(desempleo_total$country,desempleo_total$date,desempleo_total$SL.UEM.TOTL.ZS)
desempleo_total <-desempleo_total%>%
  rename(
    países = "desempleo_total$country",
    fecha ="desempleo_total$date",
    desempleo_t ="desempleo_total$SL.UEM.TOTL.ZS"
  )
desempleo_total <-drop_na(desempleo_total)
desempleo_total_prom <- aggregate(desempleo_total$desempleo_t, list(desempleo_total$países), FUN=mean)
desempleo_total_prom <- desempleo_total_prom %>%
  rename(
    países = Group.1, DESP=x
  )

```

Se incluirá la Tasa promedio de inflación para explicar su efecto parcial sobre el desempeño deportivo en los juegos olímpicos.

```

inflacion <- wb_data("NY.GDP.DEFL.KD.ZG", start_date = 1950, end_date = 2016)
inflacion<- tibble(inflacion$country,inflacion$date,inflacion$NY.GDP.DEFL.KD.ZG)
inflacion <- inflacion %>%
  rename(
    países = "inflacion$country",
    fecha = "inflacion$date",
    inflacion_t ="inflacion$NY.GDP.DEFL.KD.ZG"
  )
inflacion <- drop_na(inflacion)

inflacion_prom <- aggregate(inflacion$inflacion_t, list(inflacion$países), FUN=mean)
inflacion_prom <-inflacion_prom %>%
  rename(
    países = Group.1,INF=x
  ) %>%
  mutate(INF2=INF^2)

```

Finalmente, se hace un proceso de adjunción de todas las variables en un mismo objeto.

```

datos <- left_join(medallas_por_pais, growth_pob_prom,by = "países")
datos1 <- left_join(datos,growth_gdp_prom,by = "países")
datos2 <- left_join(datos1, desempleo_total_prom,by = "países")
tidy_data<- left_join(datos2, inflacion_prom,by = "países")

tidy_data <- drop_na(tidy_data)
tidy_data <- tidy_data %>%
  relocate(países,medallas,GDP,POB,DESP,INF)
head(tidy_data)

```

```

## # A tibble: 6 x 9
##   países      medallas  GDP  POB  DESP  INF  POB2  GDP2  INF2
##   <chr>      <int> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
## 1 United States    2847  2.00  1.04  6.07  3.40  1.08    4.00  11.6
## 2 Germany          1019  1.88  0.220  7.72  2.55  0.0483  3.52  6.51
## 3 United Kingdom    898  2.03  0.402  6.74  5.61  0.161    4.13  31.4
## 4 France           863  2.18  0.640  9.88  4.28  0.410    4.74  18.3
## 5 Italy             716  2.11  0.337  9.90  6.65  0.114    4.47  44.3
## 6 China            608  6.85  1.30   3.88  3.60  1.68   46.9  13.0

```

## Estadísticas descriptivas

```

resumen_países <- tidy_data %>%
  summary()
resumen_países

```


```

##   países      medallas      GDP      POB
## Length:121   Min.    : 1.0   Min.   :-1.976   Min.   :-0.1763
## Class :character 1st Qu.: 2.0   1st Qu.: 1.449   1st Qu.: 0.5637
## Mode  :character Median : 15.0   Median : 2.202   Median : 1.5525
##          Mean   : 135.6   Mean   : 2.265   Mean   : 1.6810
##          3rd Qu.: 96.0   3rd Qu.: 2.865   3rd Qu.: 2.3532
##          Max.   :2847.0   Max.    : 6.848   Max.    : 8.2464
##   DESP      INF      POB2      GDP2
## Min.    : 0.4885   Min.    : 1.201   Min.    : 0.00022   Min.    : 0.02327
## 1st Qu.: 4.0869   1st Qu.: 4.683   1st Qu.: 0.31771   1st Qu.: 2.11517
## Median : 7.3269   Median : 7.837   Median : 2.41011   Median : 4.84836
## Mean    : 8.3341   Mean    : 28.004   Mean    : 4.66673   Mean    : 7.18799
## 3rd Qu.:11.1727   3rd Qu.: 18.194   3rd Qu.: 5.53775   3rd Qu.: 8.21039
## Max.    :33.1550   Max.    :455.599   Max.    :68.00310   Max.    :46.89291
##   INF2
## Min.    : 1.44
## 1st Qu.: 21.93
## Median : 61.42
## Mean    : 4527.76
## 3rd Qu.: 331.04
## Max.    :207570.06

```


## Medallas y PIB

```
tidy_data %>%
  group_by(países,medallas) %>%
  head(15)%>%
  ggplot(aes(x=reorder(países,medallas),y=medallas, fill=países)) +
  geom_col() + coord_flip() + labs(title = "Total de medallas ganadas", x= "Países", y= "Medallas")+
  theme_solarized(light = T) + scale_colour_solarized('green')+theme(text = element_text(family = "serif",
plot.title = element_text(face = "bold.italic", hjust = 0.5))+ theme(legend.position = "bottom")+theme
```



```
ggplot(tidy_data, aes(x = tidy_data$GDP)) +
  geom_histogram(position = "identity", color = "Yellow",alpha = 0.9)+
  theme(legend.position = "top") +
  ggtitle("Histograma PIB") +
  ylab("Frecuencia") +
  xlab("Crecimiento del PIB (%)")
```

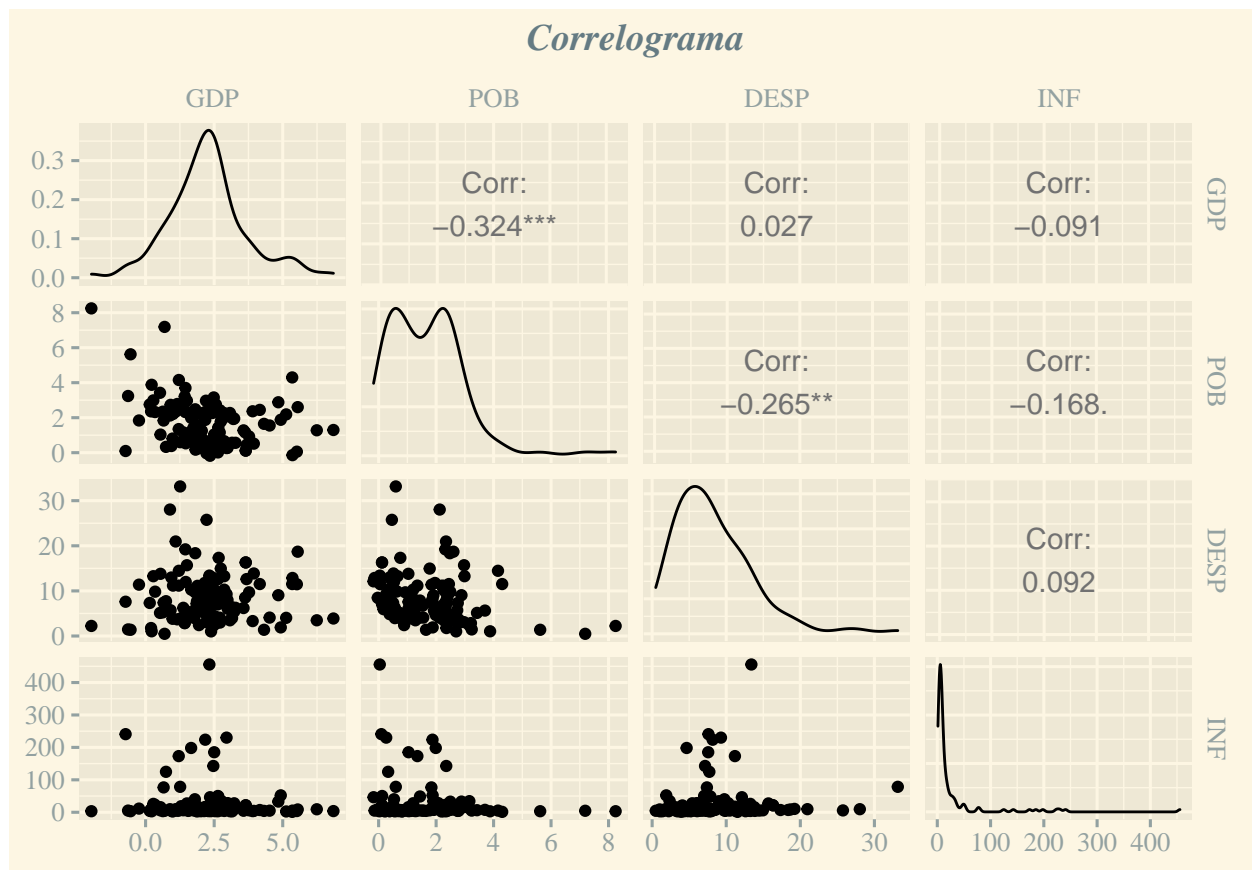
### Histograma PIB



Al analizar los diagramas de dispersión, se observa que la gran mayoría de pares ordenados presentan correlaciones negativas entre sí, a excepción de la relación entre la inflación y el desempleo. Se encuentra además que la matriz de correlación expone 3 ejemplares significativos. La primera es el desempleo y la población, la cual llega a ser significativa a al 5%, y es de carácter negativa. La segunda es la relación entre el desempleo y el PIB, la cual es significativa al 10% e inversa. La tercera es la relación entre la inflación y el PIB, la cual es significativa al 10% y presenta una relación inversa entre sí. Finalmente, se encuentra que la relación entre la inflación y el desempleo es de carácter positiva, por lo que se establece que mayores niveles de inflación están asociados con mayores niveles de desempleo, tal y como afirma la teoría económica al describir el postulado de Curva de Phillips.


### Correlaciones

```
ggpairs(tidy_data, columns = 3:6, method = c("everything", "pearson"), title="Correlograma", color="red",
plot.title = element_text(face = "bold.italic", hjust = 0.5))+ theme(legend.position = "bottom")+theme
```




### Dispersión de los datos

```
ggplot(data = tidy_data, aes(x =medallas,y =GDP)) +
  geom_point(color="blue") +
  labs(title = "Diagrama de dispersión", x= "Medallas", y= "PIB a precios corrientes")+theme_solarized(lig
  plot.title = element_text(face = "bold.italic", hjust = 0.5))+ theme(legend.position = "bottom")+theme
```




```
ggplot(data = tidy_data, aes(x =medallas,y =POB)) +
  geom_point(color="red") +
  labs(title = "Diagrama de dispersión", x= "Medallas", y= "Crecimiento poblacional promedio")+ theme_sol
plot.title = element_text(face = "bold.italic", hjust = 0.5))+ theme(legend.position = "bottom")+theme
```






```
ggplot(data = tidy_data, aes(x =medallas,y =INF)) +
  geom_point(color="green") +
  labs(title = "Diagrama de dispersión", x= "Medallas", y= "Inflación promedio")+theme_solarized(light = '
  plot.title = element_text(face = "bold.italic", hjust = 0.5))+ theme(legend.position = "bottom")+theme
```



```
ggplot(data = tidy_data, aes(x =medallas,y =DESP)) +
  geom_point(color = "black") +
  labs(title = "Diagrama de dispersión", x= "Medallas", y= "Desempleo promedio")+theme_solarized(light = '
  plot.title = element_text(face = "bold.italic", hjust = 0.5))+ theme(legend.position = "bottom")+theme
```



### Análisis preliminar

Al haber analizado las estadísticas descriptas presentadas en los puntos anteriores, se logra observar sin lugar a duda que Estados Unidos es el país que mayor número de medallas (entre ellas; oro, plata y bronce) ha sumado a lo largo de la historia. Esto podría ser explicado parcialmente por el tamaño de la población, dado que es uno de los países participantes con mayor número de habitantes. Con respecto al análisis agregado junto con los demás países, se encuentra que la media de medallas ganadas por país desde 1950 hasta la actualidad corresponde a 132, sin embargo, este valor es bastante sensible ante valores atípicos, como lo indica la participación de Estados Unidos en los juegos internacionales.

En cuanto al PIB corriente expresado en miles de millones de dólares, se evidencia que la media corresponde a 7829mm de dólares norteamericanos, además, el grado de variabilidad es bastante alto debido a que el nivel mínimo de PIB corresponde a 159mm de dólares norteamericanos, y el máximo a 40313mm. Al haber observado el histograma de la variable anterior, se encuentra que la gran mayoría de los datos están concentrados entre el mínimo y el promedio, lo cual deja en evidencia que gran parte de los países participantes poseen bajos niveles de PIB. Además, la distribución de la variable de acuerdo con el histograma llega a presentar asimetría positiva, o hacia la derecha, lo cual establece que hay diversos niveles de producto al interior las naciones partícipes de los juegos olímpicos, donde pocos países poseen ingresos muy altos, y la gran mayoría posee ingresos relativamente bajos. Por otro lado, se descarta que el comportamiento de la variable se comporte normal, debido a la asimetría positiva.

De acuerdo con los diagramas de dispersión presentados en las tablas cruzadas, se logra establecer que todas las distribuciones presentan asimetría positiva, de manera que se rechaza parcialmente el hecho de que alguna variable logre presentar un comportamiento normal. Asimismo, algunos de los cruces presentan mayor cohesión entre las observaciones, por lo que la variabilidad de los datos es más baja para aquellas gráficas cuyas observaciones estén más juntas. Finalmente, al haber analizado el diagrama de dispersión de

la variable dependiente e independiente, se establece que se logra gestar una relación positiva, donde mayores niveles de ingreso (PIB), podrían explicar mayor número de medallas ganadas con el paso del tiempo.

## Modelo

```
mod1 <- lm(tidy_data$medallas~tidy_data$POB+tidy_data$POB2+tidy_data$GDP+tidy_data$GDP2+tidy_data$DESP+
mod2 <- lm(tidy_data$medallas~tidy_data$POB+tidy_data$GDP+tidy_data$DESP+tidy_data$INF)
mod3 <- lm(tidy_data$medallas~tidy_data$POB+tidy_data$DESP)

resumen <- stargazer(mod1,mod2,mod3, type="text", dep.var.labels = "Numero de medallas olímpicas obtenidas")
```

```
##
## =====
##                               Dependent variable:
##                               -----
##                               Numero de medallas olímpicas obtenidas
##                               (1)           (2)           (3)
## -----
## POB                -155.068***          -89.431***          -77.050***
##                   (46.969)           (23.201)           (21.562)
##
## POB2                11.690
##                   (7.907)
##
## GDP                 -24.215              -21.906
##                   (56.891)           (21.019)
##
## GDP2                1.220
##                   (9.383)
##
## DESP                -9.393*              -9.386*              -9.393*
##                   (5.320)           (5.319)           (5.317)
##
## INF                 -1.098              -0.646
##                   (1.157)           (0.473)
##
## INF2                0.001
##                   (0.003)
##
## Constant            490.895***          431.852***          343.399***
##                   (117.980)         (97.402)           (70.179)
## -----
## Observations         121                121                121
## R2                   0.145                0.122                0.103
## Adjusted R2          0.092                0.092                0.087
## Residual Std. Error 309.522 (df = 113)    309.532 (df = 116)    310.289 (df = 118)
## F Statistic         2.735** (df = 7; 113) 4.034*** (df = 4; 116) 6.745*** (df = 2; 118)
## =====
## Note:                                     *p<0.1; **p<0.05; ***p<0.01
```

```
a <- AIC(mod1)
b <- AIC(mod2)
c <- AIC(mod3)
```

```
AIC <- c(a,b,c)
AIC
```

```
## [1] 1740.984 1738.161 1736.821
```

Definimos el tercer modelo como el mejor modelo pues es el que tiene menos pérdida de información.

## Conclusiones